


Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης

Σχολή Θετικών Επιστημών



ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ

Steepest Descent Optimization & Advanced Gradient Methods

Σπυριδόπουλος Γεώργιος

gspyridop@csd.auth.gr AEM: 4619

6 Μαΐου 2026

Εισαγωγή: Η Μέθοδος Steepest Descent και το Πρόβλημα Σύγκλισης

Η μέθοδος Steepest Descent ή αλλιώς Gradient Descent αποτελεί μια βασική τεχνική βελτιστοποίησης για την εύρεση τοπικών ελαχίστων.

Αλγόριθμος Steepest Descent

1. Αρχική πρόβλεψη/διάνυσμα x_0 και ορισμός $\epsilon > 0$, $k = 0$.
2. Επαναληπτικό Βήμα:
 - α') Αν $\|\nabla f(x_k)\| < \epsilon$, τότε ο αλγόριθμος τερματίζει και η προσεγγιστική λύση είναι το x^* .
 - β') Αλλιώς, υπολογίζουμε την κατεύθυνση καθόδου $p_k = -\nabla f(x_k)$.
 - γ') Βρίσκουμε το $a_k > 0$ step-size που ελαχιστοποιεί τη συνάρτηση $\phi(a_k) = f(x_k + a_k p_k)$.
 - δ') Θέτουμε το νέο σημείο $x_{k+1} = x_k + a_k p_k$.
 - ε') Επαναλαμβάνουμε από το βήμα (α) θέτοντας $k \leftarrow k + 1$.

Το Πρόβλημα της Σύγκλισης:

Η πορεία προς το ελάχιστο είναι μία τεθλασμένη γραμμή με μεγάλο αριθμό διαδοχικών ευθύγραμμων τμημάτων τα οποία σχηματίζουν ορθές γωνίες (90°) μεταξύ τους, καθιστώντας τη μέθοδο αργή και αναποτελεσματική. Μόνο αν ξεκινήσουμε με ένα αρχικό σημείο x_0 τέτοιο ώστε το διάνυσμα προς το x^* να είναι συγγραμμικό του $\nabla f(x_0)$, ο αλγόριθμος τερματίζει σε ένα βήμα.

Μελετώντας την steepest descent στην τετραγωνική συνάρτηση $f(x) = \frac{1}{2}x^T Q x -$

$b^T x + c$, υπολογίζουμε πως ισχύει η παρακάτω ανισότητα σφάλματος:

$$\|x_{k+1} - x^*\|_Q^2 \leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^2 \|x_k - x^*\|_Q^2 \quad (1)$$

όπου $\lambda_1, \dots, \lambda_n$ είναι οι ιδιοτιμές του Q . Συμπεραίνουμε λοιπόν, πως στην συγκεκριμένη περίπτωση συγκλίνει γραμμικά.

Momentum - Heavy-Ball

Why Momentum Really Works [1]

Το άρθρο αναφέρεται στην μέθοδο momentum ή αλλιώς heavy-ball και αναλύει τον ρυθμό σύγκλισής τους στην τετραγωνική συνάρτηση $f(w) = \frac{1}{2} w^T A w - b^T w$, συγκριτικά με την steepest descent.

Τύπος και σύγκριση

Στην κλασική steepest descent, έχουμε:

$$w^{k+1} = w^k - a \nabla f(w^k) \quad (2)$$

ενώ στη μέθοδο momentum, εισάγεται η έννοια της μνήμης για να αποτραπούν οι απότομες ταλαντώσεις:

$$z^{k+1} = \beta z^k + \nabla f(w^k) \quad \text{και} \quad w^{k+1} = w^k - a z^{k+1} \quad (3)$$

Στην τετραγωνική συνάρτηση η steepest descent επιτυγχάνει με βέλτιστο βήμα

$a^* = \frac{2}{\lambda_n + \lambda_1}$, ρυθμό σύγκλισης:

$$\text{rate}(a^*) = 1 - a^* \lambda_1 = \frac{\lambda_n/\lambda_1 - 1}{\lambda_n/\lambda_1 + 1} = \frac{\kappa - 1}{\kappa + 1} \quad (4)$$

όπου $\kappa = \frac{\lambda_n}{\lambda_1}$ είναι ο δείκτης κατάστασης (condition number). Αποδεικνύεται ότι απαιτούνται $k = O(\kappa)$ επαναλήψεις.

Στο ίδιο πρόβλημα, η μέθοδος momentum για βέλτιστα a και β :

$$a^* = \frac{4}{(\sqrt{\lambda_n} + \sqrt{\lambda_1})^2}, \quad \beta^* = \left(\frac{\sqrt{\lambda_n} - \sqrt{\lambda_1}}{\sqrt{\lambda_n} + \sqrt{\lambda_1}} \right)^2 \quad (5)$$

έχει ρυθμό σύγκλισης $\rho = \sqrt{\beta^*} = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$. Έτσι, η πολυπλοκότητα βελτιώνεται σε $O(\sqrt{\kappa})$. Ο Nesterov απέδειξε πως καμία άλλη μέθοδος στη κλάση των γραμμικών μεθόδων πρώτης τάξης (linear first order methods), δεν έχει καλύτερο ρυθμό για τετραγωνικές συναρτήσεις. Γενικότερα, η μέθοδος momentum έχει τον προαναφερόμενο ρυθμό σε τετραγωνικές συναρτήσεις.

Nesterov Accelerated Gradient (NAG)

Πρόβλεψη Μετάβασης (NAG - 1983) [2]

Η μέθοδος NAG, σε αντίθεση με την momentum, προβλέπει την θέση του επόμενου βήματος και έπειτα διορθώνει χρησιμοποιώντας την κλίση στο σημείο το οποίο πιστεύει ότι περίπου θα είναι:

$$y^k = w^k + \beta(w^k - w^{k-1}) \quad (\text{Σημείο πρόβλεψης - lookahead point}) \quad (6)$$

$$w^{k+1} = w^k - a \nabla f(y^k) \quad (\text{Βήμα διόρθωσης - correction step}) \quad (7)$$

Το σημείο y^k είναι η θέση στην οποία η ορμή, χωρίς την κλίση, θα μας πήγαινε.

Η μέθοδος NAG επιτυγχάνει ρυθμό σύγκλισης $\frac{\sqrt{k}-1}{\sqrt{k}+1}$ σε όλες τις κυρτές συναρτήσεις, όχι μόνο στην τετραγωνική όπως η μέθοδος momentum.

Μέθοδοι Κλίσης με Βήμα Δύο Σημείων (Barzilai-Borwein)

Barzilai-Borwein Method [3]

Οι J. Barzilai και J. Borwein πρότειναν μία μέθοδο που το βήμα a_k υπολογίζεται συναρτήσει της τωρινής και της προηγούμενης επανάληψης. Για τις διαφορές των θέσεων και κλίσεων:

$$\Delta x = x_k - x_{k-1}, \quad \Delta g = \nabla f(x_k) - \nabla f(x_{k-1}) \quad (8)$$

υπάρχουν δύο εναλλακτικές.

- **BB1 (Long-step):** Ελαχιστοποιεί την ποσότητα $\|\Delta x - a\Delta g\|^2$, δίνοντας τον τύπο:

$$a_k = \frac{\langle \Delta x, \Delta x \rangle}{\langle \Delta x, \Delta g \rangle} \quad (9)$$

- **BB2 (Short-step):** Ελαχιστοποιεί την αντίστοιχη ποσότητα για τον αντίστροφο μετασχηματισμό, δίνοντας τον τύπο:

$$a_k = \frac{\langle \Delta x, \Delta g \rangle}{\langle \Delta g, \Delta g \rangle} \quad (10)$$

Έτσι, για παράδειγμα στην τετραγωνική συνάρτηση, η μέθοδος BB έχει πολυπλοκότητα $O(n)$, λόγω εσωτερικού γινομένου, ενώ η steepest descent έχει $O(n^2)$

Θεωρητικό Συμπέρασμα

Διαπιστώνεται ότι οι μέθοδοι Momentum και NAG λειτουργούν αποδοτικότερα για σταθερό και βέλτιστο α (learning rate) και β (momentum/memory term). Αντίθετα, η κλασική Steepest Descent και η Barzilai-Borwein βασίζονται στο παρόν ή και το παρελθόν για τον υπολογισμό του βήματος.

Είναι σημαντικό να τονιστεί πως οι τέσσερις παραπάνω τεχνικές ανήκουν οικογένεια των μεθόδων βελτιστοποίησης πρώτης τάξης. Συνεπώς, η κατεύθυνσή τους επηρεάζεται απολύτως και άμεσα από την τωρινή κλίση συνάρτησης. Αποτελεσματικά, για μη-κυρτές (non-convex) συναρτήσεις, είναι πιθανό να παγιδευτούν σε τοπικά ελάχιστα καθώς δεν υπάρχει πλήρης εικόνα του χώρου.

Πειραματικά Αποτελέσματα

Για να αξιολογηθούν οι παραπάνω μέθοδοι πραγματοποιήθηκαν 30 ανεξάρτητες εκτελέσεις για την κάθε μέθοδο πάνω σε 7 συναρτήσεις με γνωστά ολικά ελάχιστα, κάποιες από τις οποίες δεν ήταν κυρτές. Τα συμπεράσματα βγαίνουν από τη μέση τιμή και την τυπική απόκλιση του αντίστοιχου αποτελέσματος αλλά και του αριθμού επαναλήψεων.

Κυρτές/Convex Συναρτήσεις

Στις κυρτές συναρτήσεις, Sphere, Quadratic, Booth, Matyas, όπου υπάρχει ένα μοναδικό ολικό ελάχιστο, βλέπουμε πως όλες οι μέθοδοι συγκλίνουν. Η μέθοδος BB1 αποδείχθηκε η ταχύτερη και η σταθερότερη με αρκετή διαφορά. Παράλληλα, οι μέθοδοι momentum και NAG φαίνεται να χρειάζονται παραπάνω επαναλήψεις από τις άλλες δύο καθώς υπάρχουν ταλαντώσεις, λόγω σταθερού βήματος, γύρω από το ελάχιστο.

Μη-Κυρτές/Non-Convex Συναρτήσεις

Στις μη-κυρτές συναρτήσεις, Rastrigin, Rosenbrock, Ackley, υπάρχουν πολλά τοπικά ελάχιστα και οι μέθοδοι μπορεί να παγιδευτούν αν δεν υπάρξει σωστή αρχικοποίηση. Αυτό φαίνεται διότι οι μέθοδοι σπάνια θα βρουν το ολικό ελάχιστο. Παρόλα αυτά, οι μέθοδοι momentum και NAG καταφέρνουν πιο συχνά να "ξεφύγουν" από τοπικά ελάχιστα.

Συνάρτηση	Μέθοδος	Μέσο $f(x) \pm$ Τυπ. Απόκλ.	Επαναλήψεις $\pm$ Τυπ. Απόκλ.
Sphere (n=15)	Steepest Descent	0.00 ± 0.00	1.0 ± 0.0
	Heavy Ball	0.00 ± 0.00	362.0 ± 0.0
	NAG	0.00 ± 0.00	1001.0 ± 0.0
	BB1	0.00 ± 0.00	2.0 ± 0.0
Quadratic (n=2)	Steepest Descent	-0.50 ± 0.00	12.5 ± 6.8
	Heavy Ball	-0.50 ± 0.00	146.5 ± 7.0
	NAG	-0.50 ± 0.00	1001.0 ± 0.0
	BB1	-0.50 ± 0.00	8.2 ± 3.5
Booth (n=2)	Steepest Descent	0.00 ± 0.00	18.7 ± 14.8
	Heavy Ball	0.00 ± 0.00	385.5 ± 18.2
	NAG	0.00 ± 0.00	967.5 ± 64.4
	BB1	0.00 ± 0.00	8.8 ± 2.0
Matyas (n=2)	Steepest Descent	0.00 ± 0.00	30.8 ± 48.2
	Heavy Ball	0.00 ± 0.00	308.4 ± 16.9
	NAG	0.00 ± 0.00	793.4 ± 48.2
	BB1	0.00 ± 0.00	7.9 ± 2.3
Rastrigin (n=15)	Steepest Descent	133.16 ± 20.52	364.2 ± 240.8
	Heavy Ball	7.06 ± 2.04	453.9 ± 3.9
	NAG	7.83 ± 1.95	82.8 ± 2.8
	BB1	412.58 ± 410.70	543.0 ± 419.5
Rosenbrock (n=15)	Steepest Descent	3.70 ± 2.04	1000.0 ± 0.0
	Heavy Ball	8.31 ± 2.33	1000.0 ± 0.0
	NAG	13.31 ± 2.75	1001.0 ± 0.0
	BB1	11.73 ± 10.76	997.9 ± 11.3
Ackley (n=2)	Steepest Descent	1.57 ± 2.01	1000.0 ± 0.0
	Heavy Ball	4.73 ± 2.37	432.7 ± 190.8
	NAG	5.32 ± 1.67	110.1 ± 18.2
	BB1	12.01 ± 7.61	291.3 ± 428.9

Πίνακας 1: Ενδεικτικά Αποτελέσματα

Αναφορές

- [1] Gabriel Goh. Why momentum really works. *Distill*, 2(4):e6, 2017.
- [2] Sebastian Ruder. An overview of gradient descent optimization algorithms. *arXiv preprint arXiv:1609.04747*, 2016.
- [3] Jonathan Barzilai and Jonathan M. Borwein. Two-point step size gradient methods. *IMA Journal of Numerical Analysis*, 8(1):141–148, 1988.